

Asignatura: Computación Paralela y Distribuida

INFORME TÉCNICO

Trabajo N°2: Análisis estadístico de
datos de ventas

Profesor:

Sebastián Salazar Molina

Alumnos:

Renato Álvarez Ramos
Cristopher Retamales Pedreros

Sección: 411

Fecha: 10 de julio de 2026

Índice

1. Descripción de la Solución Implementada	2
2. Justificación de las Librerías Estadísticas Utilizadas	2
3. Arquitectura Paralela y Evaluación Empírica de Rendimiento	3
3.1. Entorno de Ejecución y Reproducibilidad	3
3.2. Metodología del <i>Benchmark</i>	4
3.3. Resultados: Descomposición por Sub-fase	5
3.4. Interpretación: el dilema GIL vs. IPC	5
3.5. Verificación de Integridad, Determinismo y Barrido de Particiones .	6
3.6. Conclusión y Planificador Seleccionado	7
4. Fase 1: Preprocesamiento y Limpieza	8
4.1. Tratamiento de Valores Faltantes	8
4.2. Transformación de Variables y Derivadas	9
4.3. Detección de Outliers y Estandarización	9
5. Fase 2: Análisis Exploratorio Estadístico (EDA)	10
5.1. Pruebas de Normalidad	10
5.2. Análisis de Asociación	11
5.3. Patrones Temporales	13
6. Fase 3: Inferencia Estadística	16
7. Fase 4: Modelado Predictivo (Regresión OLS)	17
7.1. Validación y Diagnóstico de Supuestos	18
7.2. Interpretación Crítica y Extrapolabilidad	20
8. Síntesis de Resultados (Cuadro de Mando)	20
9. Conclusiones y Recomendaciones de Negocio	22
10. Dificultades Encontradas y Solución de Problemas	23
A. Anexo A: Ejecución de Referencia (Prueba de Ejecución)	23

1 Descripción de la Solución Implementada

Para resolver el desafío de analizar el archivo `ventas_completas.csv` (que contiene más de 3,2 millones de registros) de la cadena Cruz Morada, se implementó una solución computacional escalable utilizando procesamiento paralelo.

Justificación de la Técnica: Dado que cargar un archivo tan masivo directamente a la memoria RAM con herramientas tradicionales (como `pandas`) provocaría colapsos por falta de memoria (Out-of-Memory), se optó por una lectura particionada o *chunking*. La ejecución se realiza en bloques de 64 MB, asignando cada partición lógica como una tarea independiente entre los **10 núcleos lógicos** (4 de rendimiento + 6 de eficiencia) del procesador Apple M4 del equipo de pruebas. El motor paralelo expone el planificador de Dask como parámetro configurable (`synchronous`, `threads`, `processes` y `distributed/LocalCluster`); la Sección 3 documenta la evaluación empírica que fundamenta la elección del planificador por defecto. Además, cumpliendo con la estricta política de reproducibilidad, se garantiza el determinismo del programa inyectando una semilla global mediante la variable de entorno `CPYD_SEED=42`.

Proyección de columnas (memoria y privacidad): De las 15 columnas del archivo original, la lectura con Dask carga únicamente las 9 requeridas por el análisis (`FECHA`, `CANAL`, `UNIDADES`, `PORCENTAJE_DESCUENTO`, `MONTO_APLICADO`, `LOCAL`, `CODIGO_CLIENTE`, `FECHA_NACIMIENTO` y `GENERO`). Se descartan en la propia lectura `SKU`, `PRODUCTO`, `BOLETA`, `RUN_CLIENTE`, `NOMBRES` y `APELLIDOS` por dos motivos: (i) reducen el consumo de memoria y el tiempo de parseo, al no materializar columnas de texto pesadas ni identificadores no utilizados; y (ii) `RUN_CLIENTE`, `NOMBRES` y `APELLIDOS` son datos personales identificables, cuya exclusión minimiza el tratamiento de información sensible. El identificador `CODIGO_CLIENTE (UUID)` se conserva sólo para calcular la frecuencia de compra por cliente y se elimina inmediatamente después de dicho cómputo. Adicionalmente, se declaran los tipos de dato explícitos por columna (p. ej. `Int32`, `Int8`, `category`, `float64`) para evitar la inferencia costosa y acotar la huella de memoria.

2 Justificación de las Librerías Estadísticas Utilizadas

Para asegurar un rigor metodológico excepcional, se utilizaron las siguientes librerías de Python, consideradas estándares industriales en la ciencia de datos:

- **Dask:** Utilizado para el paralelismo nativo. Es una extensión de `Pandas` que permite procesar *dataframes* que exceden la capacidad de la memoria RAM.
- **SciPy** (`scipy.stats`): Se seleccionó para las pruebas de normalidad (Shapiro-Wilk, Kolmogorov-Smirnov), independencia (Chi-cuadrado) y comparación de medianas (Kruskal-Wallis, Mann-Whitney U). Provee implementaciones altamente optimizadas y matemáticamente exactas de estos contrastes de hipótesis.

- **Statsmodels:** Empleado para la regresión lineal (OLS) y sus diagnósticos. A diferencia de `scikit-learn` (enfocado puramente en predicción *machine learning*), `statsmodels` está diseñado explícitamente para la *inferencia estadística*, ofreciendo tablas detalladas de coeficientes, p-values, errores estándar, y tests robustos (Breusch-Pagan, Durbin-Watson, VIF). También aporta la descomposición estacional de series de tiempo y las funciones ACF/PACF.
- **pandas y NumPy:** base del cómputo tabular y numérico. `pandas` provee las estructuras de datos (y respalda a Dask, que replica su API sobre particiones); `NumPy` aporta el álgebra vectorizada subyacente (incluidos los cálculos de tamaños de efecto y VIF).
- **scikit-learn:** utilizado *exclusivamente* para tareas de *machine learning* bien acotadas donde es el estándar: la partición reproducible `train_test_split` (70/30 con semilla), las métricas de validación (RMSE, MAE, R^2) y el `StandardScaler` (z-score con parámetros documentados). La inferencia se delega a `statsmodels`, no a esta librería.
- **matplotlib y seaborn:** generación de todas las visualizaciones (histogramas con densidad, boxplots, mapa de calor de correlaciones, descomposición temporal, ACF/PACF y diagnósticos de residuos). `seaborn` se usa por su integración estadística directa (KDE, heatmap) sobre `matplotlib`.

3 Arquitectura Paralela y Evaluación Empírica de Rendimiento

Un objetivo central del trabajo es que la solución sea *eficiente y escalable*, no simplemente “paralela”. Por ello, en lugar de asumir que el paralelismo garantiza aceleración, se sometió el motor a una evaluación empírica rigurosa que compara cuatro planificadores de Dask sobre la fase de carga y preprocesamiento (la única etapa efectivamente paralelizada del *pipeline*). Los hallazgos son deliberadamente autocríticos: revelan que la elección ingenua del planificador puede **degradar** el rendimiento por debajo del secuencial, y que la aceleración real exige entender la tensión entre el *GIL* de Python y el costo de la comunicación entre procesos (IPC).

3.1 Entorno de Ejecución y Reproducibilidad

Todas las mediciones se ejecutaron en un único equipo, con caché de disco tibia (*warm-cache*) y la semilla determinista `CPYD_SEED=42`. La Tabla 1 documenta el entorno exacto para garantizar la reproducibilidad de las cifras.

Componente	Especificación
Procesador	Apple M4 (ARM64), 10 núcleos lógicos (4P + 6E)
Memoria RAM	16 GB
Sistema operativo	macOS 26.5.1 (build 25F80)
Intérprete	CPython 3.11.15
Arranque de <i>multiprocessing</i>	spawn
Dask / Distributed	2026.7.0 / 2026.7.0
pandas / NumPy / SciPy	3.0.3 / 2.4.6 / 1.17.1
statsmodels / scikit-learn	0.14.6 / 1.9.0
Semilla determinista	CPYD_SEED=42

Tabla 1: Entorno de ejecución y versiones utilizadas en el *benchmark* (reproducibilidad).

Nota sobre determinismo bajo spawn: en macOS los *workers* de proceso no heredan la semilla del proceso padre. Esto no compromete el determinismo porque las operaciones ejecutadas dentro de los *workers* (*fillna*, *clip*, *groupby*, *map*, *quantile*) son puramente deterministas; todo muestreo aleatorio (partición *train/test*, muestras para diagnósticos) ocurre en el proceso principal *después* de `.compute()`, donde la semilla sí está fijada.

3.2 Metodología del *Benchmark*

Cada configuración se midió con 1 ejecución de calentamiento (descartada) más 3 ejecuciones cronometradas con `time.perf_counter()`, bloques de 64 MB y 10 *workers*. Para localizar el origen de los costos, cada ejecución se descompuso en cuatro sub-fases: (i) construcción del pool/cluster (*setup*); (ii) carga y primera evaluación del grafo (*persist()*); (iii) reducciones intermedias (mediana de edad, conteo de edades inválidas, límites IQR, frecuencia por cliente, estadísticos descriptivos y las dos tablas de contingencia MCAR: ocho invocaciones a `.compute()` en total); y (iv) materialización final del *dataframe* de 3,2M filas al proceso principal. En paralelo, un hilo muestreó la memoria máxima del sistema y los *bytes* enviados a *swap*, para distinguir un cuello de botella real de IPC de una simple presión de memoria.

3.3 Resultados: Descomposición por Sub-fase

Sub-fase (s)	Secuencial synchronous	Hilos threads	Procesos processes	LocalCluster distributed
Configuración (<i>setup</i>)	0,00	0,00	0,00	2,32
Construcción del grafo	0,01	0,01	0,01	0,01
Carga + persist()	5,34	3,91	4,90	1,37
Reducciones intermedias	13,45	10,37	38,75	7,31
Materialización final	0,68	0,68	9,71	8,53
TOTAL	19,47	14,97	53,37	17,23
<i>Aceleración vs. secuencial</i>	1,00×	1,30×	0,36×	1,13×

Tabla 2: Descomposición del tiempo de Carga+Preprocesamiento (media de 3 ejecuciones, en segundos). Se resaltan en **negrita** el mejor tiempo total y las sub-fases donde el planificador *processes* colapsa.

Consumo de recursos (peor caso entre ejecuciones): la memoria máxima del sistema osciló entre 5,98 y 7,08 GB de los 16 GB disponibles, y el envío a *swap* nunca superó los 6,8 MB en **ninguna** configuración. Esto **descarta** que la lentitud de *processes* se deba a paginación por falta de memoria: el sobre costo es genuinamente de serialización (IPC).

3.4 Interpretación: el dilema GIL vs. IPC

- **Hilos (threads) — 1,30×**: es el planificador más rápido y estable ($\pm 0,15$ s). La aceleración es modesta porque el *GIL* de Python impide que las operaciones de *pandas* (intensivas en CPU) se ejecuten simultáneamente; la ganancia proviene casi por completo de la fase de E/S (descompresión y parseo del CSV), que libera el *GIL*. Los *workers* comparten memoria, por lo que no hay costo de serialización.
- **Procesos (processes) — 0,36× (regresión)**: contraintuitivamente, el paralelismo “real” resultó casi **tres veces más lento** que el baseline secuencial. La descomposición localiza el problema con precisión: las *reducciones intermedias* se disparan de ~ 13 a **38,75 s** y la *materialización final* de 0,68 a **9,71 s**. Bajo *spawn*, cada una de las ocho llamadas a `.compute()` obliga a serializar (*pickle*) los datos a través de las fronteras de proceso, y el volcado final de 3,2M filas al proceso principal debe empaquetarse por completo. Como el *swap* es nulo, se confirma que se trata de un cuello de botella de **IPC**, no de memoria.
- **LocalCluster (distributed) — hasta 5× más rápido que processes**: el planificador distribuido recupera el paralelismo por procesos. Es 3,10× más rápido que *processes* en promedio y alcanza $\sim 10,7$ s en régimen estacionario (ejecuciones 2 y 3), es decir 1,81× sobre el baseline: el mejor resultado

absoluto. La clave es que construye el *pool* una sola vez y `persist()` mantiene las particiones *residentes en los workers* (`persist` de 1,37 s frente a 4,90 s), de modo que las reducciones intermedias caen a 7,31 s, **incluso por debajo del secuencial**. Su costo es un *setup* de 2,32 s y una primera materialización más costosa (la varianza alta de la Tabla 2 proviene de la ejecución 1, con un *gather* inicial de 21,4 s que se estabiliza en $\sim 2,1$ s en las siguientes).

Límite de Amdahl. Sólo la fase de Carga+Preprocesamiento es paralelizable; el EDA, la inferencia y el modelado OLS son secuenciales (un “residuo serial” fijo de ~ 3 s, independiente del planificador). Por tanto, la aceleración global del *pipeline* está acotada por la ley de Amdahl con independencia del número de núcleos: optimizar el preprocesamiento tiene rendimientos decrecientes sobre el tiempo total.

3.5 Verificación de Integridad, Determinismo y Barrido de Particiones

Un segundo arnés de medición (`benchmark.py`) ejecuta el *pipeline completo* —no sólo el preprocesamiento— bajo los tres planificadores de una sola máquina, y añade tres verificaciones exigidas por el rigor metodológico: integridad numérica, determinismo y el barrido de tamaño de partición que justifica la configuración de 64 MB. La Tabla 3 confirma empíricamente el argumento de Amdahl: las fases EDA, Inferencia y OLS son *indistinguibles* entre planificadores (aceleración 0,97–1,08 $\times$, es decir ruido), y sólo Carga+Preprocesamiento responde al planificador.

Fase	¿Dask-paralela?	synchronous	threads	processes
Carga+Preprocesamiento	Sí	19,61 $\pm$ 0,14	15,40 $\pm$ 0,14	60,98 $\pm$ 0,15
EDA (pandas/scipy)	No	1,92 $\pm$ 0,03	1,91 $\pm$ 0,03	1,91 $\pm$ 0,01
Inferencia (scipy)	No	0,61 $\pm$ 0,00	0,62 $\pm$ 0,00	0,63 $\pm$ 0,00
OLS (statsmodels)	No	0,48 $\pm$ 0,02	0,43 $\pm$ 0,01	0,40 $\pm$ 0,01
TOTAL	Mixta	22,62 $\pm$ 0,11	18,36 $\pm$ 0,14	63,92 $\pm$ 0,16

Tabla 3: Tiempo del *pipeline* completo por fase (media $\pm$ desv. de 3 ejecuciones, en segundos). Los tiempos absolutos difieren de la Tabla 2 (medida en otra sesión) por la variabilidad térmica/de carga de la máquina entre ejecuciones (hasta $\sim 15\%$); las **razones de aceleración y las conclusiones son invariantes** (`threads` $\approx 1,3\times$, `processes` $\approx 0,3\times$), como también lo son la integridad y el determinismo.

Integridad numérica. El arnés extrae 26 métricas del *pipeline* (conteos de filas/outliers/clientes, estadísticos descriptivos, *p*-values, estadísticos de prueba y coeficientes OLS) y las contrasta contra los valores de referencia. El resultado es **26/26 coincidencias (0 fallos, 0 faltantes) en las tres configuraciones** de planificador, con tolerancia relativa $< 10^{-3}$. Esto demuestra que cambiar el modelo de ejecución (secuencial, hilos o procesos) no altera ni un solo resultado analítico: la paralelización es correcta, no sólo rápida.

Determinismo. Dos ejecuciones adicionales bajo `processes` con la misma semilla produjeron **37/37 salidas idénticas** bit a bit (0 divergencias). Esto confirma empíricamente la propiedad discutida en la Sección 3: aunque bajo `spawn` los *workers* no heredan la semilla, el resultado es determinista porque toda la aleatoriedad reside en el proceso principal tras `.compute()`.

Barrido de tamaño de partición. Para fundamentar el valor de 64 MB se midió la fase Carga+Preprocesamiento (bajo `processes`) con tres tamaños de bloque (Tabla 4).

Tamaño de bloque	Media $\pm$ Std (s)	vs. 64 MB
32 MB	72,16 $\pm$ 0,28	1,17×
64 MB	61,81 $\pm$ 0,30	1,00× (óptimo)
128 MB	76,36 $\pm$ 0,76	1,24×

Tabla 4: Barrido de tamaño de partición sobre Carga+Preprocesamiento (planificador `processes`, media de 3 ejecuciones).

64 MB es el óptimo empírico. Con 32 MB se generan demasiadas particiones pequeñas: crece el sobrecosto de planificación de tareas y el número de transferencias entre procesos (de ahí también su alta varianza, $\pm 11,3$ s). Con 128 MB las particiones son pocas y grandes: se pierde granularidad de paralelismo y cada transferencia IPC es más voluminosa. 64 MB equilibra ambos extremos, minimizando el tiempo con una varianza mínima ($\pm 0,65$ s).

Nota sobre advertencias en pantalla. Durante el cálculo de estadísticos descriptivos, `numpy` emite una `RuntimeWarning` (“invalid value encountered in scalar divide”) al computar la asimetría y curtosis de UNIDADES: al tener varianza cero, dichos momentos son $0/0 = \text{NaN}$. Es un resultado esperado y controlado (se reporta como NA) que no afecta ninguna otra métrica; en `main.py` se suprime explícitamente esta advertencia benigna para mantener limpia la salida.

3.6 Conclusión y Planificador Seleccionado

Para esta carga de trabajo *memory-bound* (tablas densas que caben en RAM, en una sola máquina de 10 núcleos), el planificador `threads` ofrece el mejor equilibrio entre velocidad y robustez (1,30× estable, sin sobrecosto de arranque) y es, por ello, el **planificador por defecto de la solución entregada**. El planificador `processes` se descarta explícitamente por su regresión de rendimiento. `LocalCluster` se documenta como la vía de escalamiento correcta: es el más rápido en régimen estacionario y sería la elección obligada si el conjunto excediera la memoria o se distribuyera en múltiples nodos, escenarios en los que su modelo de datos residentes amortiza el sobrecosto inicial. El hallazgo metodológico central es que, en Python, el paralelismo de datos tabulares está atrapado entre estar *limitado por el GIL* (hilos) o *limitado por IPC* (procesos ingenuos), y que sortear ese dilema exige un planificador que minimice el trasiego de datos entre procesos.

4 Fase 1: Preprocesamiento y Limpieza

4.1 Tratamiento de Valores Faltantes

Para abordar posibles valores faltantes en la columna PORCENTAJE DESCUENTO, se preparó una prueba de independencia Chi-cuadrado entre el indicador de nulidad y el CANAL de venta (para determinar MCAR vs MAR).

Prueba MCAR (Evaluación de Nulos):

```
--- Prueba de mecanismo de valores faltantes (MAR vs MCAR) ---
Proporcion de nulos en PORCENTAJE DESCUENTO (muestra 50.000): 0,0000%
No hay valores nulos suficientes para la prueba de independencia.
```

Justificación: Se comprobó empíricamente que la tasa de nulos era del 0,0 %, haciendo matemáticamente imposible (e innecesaria) la ejecución del test de independencia. No obstante, se mantuvo una imputación preventiva por defecto (0,0) como código de seguridad y resguardo lógico en caso de inconsistencias fuera de la muestra para los 3,2 millones de registros completos.

Prueba MCAR — FECHA NACIMIENTO:

```
--- Prueba de mecanismo de valores faltantes para FECHA NACIMIENTO ---
```

```
Proporción de nulos globales (muestra de 3.242.878): 0,0000%
```

```
Tabla de contingencia (CANAL vs FECHA NACIMIENTO nulo):
```

FECHA_NAC_ES_NULO	0
CANAL	
APP	43.238
CCT	304
POS	3.119.349
WEB	79.987

```
No hay valores nulos suficientes en la muestra para la
prueba de independencia con CANAL.
```

```
Proporción de nulos globales (muestra de 3.242.878): 0,0000%
```

```
No hay valores nulos suficientes en la muestra para la
prueba de independencia con LOCAL.
```

Justificación: Se evaluó la posible dependencia de los valores nulos frente a las variables CANAL y LOCAL. Al igual que con el porcentaje de descuento, se demostró mediante conteo paralelo en toda la base de datos (3.242.878 registros) que la tasa de nulos verdaderos (ausencia de registro, 'NaN') en la FECHA NACIMIENTO es exactamente del 0,0 %. Dado que no existen verdaderos nulos iniciales en la columna, el test estadístico de mecanismo MCAR vs MAR/MNAR es inherentemente inaplicable por falta de varianza en la condición de nulidad.

Es imperativo distinguir conceptualmente este análisis de nulidad estructural del tratamiento de validación de dominio (outliers lógicos). Las 2.876 edades lógicamente inválidas (ej. < 0 o > 110 años) identificadas y corregidas posteriormente en la Fase 1 **no son registros nulos (missing values)** ni responden a un mecanismo de pérdida dependiente, sino a inconsistencias de digitación o fallas en sistemas heredados que contenían fechas espurias (ej. 1900-01-01). Dado que el problema original no es un fenómeno estadístico de datos faltantes, sino un problema aislado de limpieza de atípicos sobre registros que sí existían, el uso del test MCAR no aplica, y la imputación posterior vía mediana resulta en una aproximación robusta a un problema de ruido, sin el requerimiento de estratificación por canal o local.

4.2 Transformación de Variables y Derivadas

De acuerdo a la rúbrica, se crearon nuevas variables a partir de los datos crudos:

- **EDAD:** Se calculó restando la FECHA NACIMIENTO a la FECHA de la transacción. Durante este proceso, los valores nulos en la fecha de nacimiento original, sumados a fechas lógicamente inconsistentes (definidas estrictamente como resultar en una edad < 0 o edad > 110 años), produjeron 2.876 registros atípicos. Estos fueron imputados limpiamente por la mediana global (49,9 años) calculada en paralelo.
- **FRECUENCIA CLIENTE:** Se calculó mediante un conteo de boletas agrupado por CODIGO CLIENTE, luego distribuido (broadcast) a todo el dataframe.
- **MONTO POR UNIDAD:** Se calculó como MONTO APLICADO / UNIDADES. Cabe destacar que, al analizar los datos descriptivos posteriormente, descubrimos que UNIDADES es siempre igual a 1 en esta base de datos. Por ende, la variable derivada MONTO POR UNIDAD resulta ser un duplicado exacto del monto pagado, lo cual es útil confirmar empíricamente.

4.3 Detección de Outliers y Estandarización

Se empleó el método del Rango Intercuartílico (IQR) sobre el MONTO APLICADO, un estimador robusto frente a distribuciones muy asimétricas.

Detección de Outliers:

Deteccion de outliers en MONTO APLICADO (metodo IQR):

Rango aceptable: [-4.562,50, 23.929,50]

Outliers detectados: 149.377 (4,61%)

Decision: se marcan pero no se eliminan.

Justificación: Se identificaron valores sobre los \$23.929,50 CLP. Por motivos de negocio, corresponden a compras verídicas de medicamentos de especialidad, por

lo que su eliminación sesgaría artificialmente a la baja el ticket promedio de la farmacia.

Finalmente, las variables continuas numéricas (PORCENTAJE DESCUENTO, MONTO APLICADO, EDAD, FRECUENCIA CLIENTE) fueron estandarizadas (z-score) computando parámetros distribuidos con Dask. Esta estandarización se calculó explícitamente para propósitos diagnósticos comparativos (análisis de componentes y comparación de escalas). Sin embargo, el modelo OLS de la Fase 4 fue alimentado deliberadamente con los valores en su escala bruta original (no estandarizada), a fin de mantener una interpretabilidad de negocio directa sobre los coeficientes monetarios y porcentuales de la regresión.

5 Fase 2: Análisis Exploratorio Estadístico (EDA)

En esta fase se caracterizan las variables, comenzando por las métricas descriptivas exhaustivas.

Estadísticas Descriptivas Completas:

	UNIDADES	DESCUENTO	MONTO	EDAD	FRECUENCIA
Media	1,00	0,392	10.179,9	49,57	5,654
Mediana	1,00	0,400	7.662,0	48,62	4,000
Varianza	0,00	0,011	2.08e08	279,71	29,769
Desv. Estandar	0,00	0,108	14.453,2	16,72	5,456
Minimo	1,00	0,000	15,0	0,00	1,000
Maximo	1,00	1,000	226.476,0	109,84	110,000
Asimetria	0,00	0,296	9,060	0,24	3,255
Curtosis	0,00	2,849	108,227	-0,78	21,517

Nota: Las Unidades muestran varianza 0 (todos los clientes llevan exactamente 1 unidad).

5.1 Pruebas de Normalidad

- **H0:** La variable proviene de una distribución normal.
- **H1:** La variable NO proviene de una distribución normal.

Pruebas de Normalidad (muestra de 5000):

MONTO APLICADO:

Shapiro-Wilk: $W=0,3967$, $p\text{-value}=2.901e-84$

Kolmogorov-Smirnov: $D=0,2539$, $p\text{-value}=1.268e-284$

Interpretación no técnica: Al obtener un p-value muy inferior a 0,05, rechazamos H0. Ninguna variable es normal. El altísimo valor de Asimetría (9,06) y Curtosis

(108,2) del MONTO explican esto, evidenciando una fuerte cola hacia la derecha, visible en el histograma.




Figura 1: Distribución del Monto




Figura 2: Distribución de la Edad




Figura 3: Distribución del Descuento

5.2 Análisis de Asociación

Dado que los datos no son normales, se descarta la Correlación de Pearson y se utiliza la **Correlación de Spearman** (basada en rangos).

Prueba de Correlación de Spearman:

MONTO vs PORCENTAJE DESCUENTO: $\rho=0,4827$, $p\text{-value}=0,0000$

Interpretación: Existe una correlación positiva moderada (0,48). A medida que el descuento es mayor, el monto total pagado suele ser mayor. El p-value $\leq 0,05$ confirma que la relación es estadísticamente significativa y no producto del azar.




Figura 4: Matriz de Correlación de Spearman

Relación entre Categorías y Análisis de Varianza: Para evaluar la independencia entre el local y el canal, y cómo estos impactan al monto, se ejecutaron pruebas de Chi-cuadrado y Kruskal-Wallis (alternativa robusta al ANOVA). Dado que el MONTO APLICADO ya demostró no ser normal (según las pruebas previas de Shapiro-Wilk y Kolmogorov-Smirnov) y presenta un comportamiento fuertemente asimétrico y heterocedástico, se viola el supuesto paramétrico de un ANOVA de una vía (distribución normal de los residuos por grupo); en consecuencia, se opta por utilizar la prueba de Kruskal-Wallis (alternativa no paramétrica basada en rangos) para contrastar la igualdad de medianas y distribuciones entre los distintos grupos.

Pruebas de Categorías y Varianza:

Chi-cuadrado de independencia (CANAL vs LOCAL):

Chi2=3.242.878,0, p-value=0,0000

Tamaño de efecto (V de Cramér): 0,5774 (asociación grande)

Kruskal (MONTO~CANAL): H=5.950,5 eta²=0,0018 (insignif.)

Kruskal (MONTO~LOCAL): H=51.345,7 eta²=0,0156 (pequeño)

Sobre significancia estadística vs. práctica (advertencia por N grande). Con $N = 3,2$ millones de filas, prácticamente cualquier prueba rechaza H_0 ($p \rightarrow 0$) por el mero tamaño muestral; el p -value deja de ser informativo. El estadístico Chi-cuadrado (3.242.878) es tan grande que iguala a N , pero un estadístico grande no equivale a un efecto fuerte. Por eso reportamos **tamaños de efecto**, que miden la magnitud real con independencia de N : la V de Cramér de 0,577 indica una asociación **fuerte** (aunque no perfecta) entre CANAL y LOCAL, explicada estructuralmente por el confinamiento de los canales online en el local virtual 1999. En cambio, aunque el monto “difiere significativamente” por canal y local, el η^2

(0,0018 y 0,0156) revela que esas diferencias explican **una fracción ínfima** de la variabilidad del ticket: significativas, pero sin relevancia práctica.

Interpretación no técnica: 1) La prueba Chi-cuadrado ($p < 0,05$) rechaza H_0 : ciertos canales operan desde locales específicos (no son independientes), y la V de Cramér confirma que la asociación es fuerte. 2) Kruskal-Wallis ($p < 0,05$) rechaza la igualdad de medianas: el monto difiere según canal y local, aunque el tamaño de efecto indica que en la práctica la diferencia es marginal.




Figura 5: Distribución del Monto según Canal de Venta

5.3 Patrones Temporales

Para cumplir con el análisis estacional, se extrajeron 390 días consecutivos, los cuales corresponden a la totalidad del rango de fechas continuas disponibles en la base de datos de transacciones. Es visible una planicie inicial cercana a cero (finales de 2023); esto corresponde a un artefacto de calidad de datos (aperturas de tienda paulatinas y sub-registro inicial de las sucursales), tras lo cual se dispara el volumen comercial estabilizándose en la primavera. Se graficó la descomposición y los gráficos ACF/PACF para analizar la autocorrelación de la demanda.




Figura 6: Descomposición Estacional y Tendencia




Figura 7: Función de Autocorrelación (ACF/PACF)

Interpretación no técnica: Los gráficos confirman una fuerte estacionalidad cíclica y tendencias a lo largo de los meses. La función ACF ratifica la alta autocorrelación (las ventas de hoy dependen estadísticamente de las ventas de ayer), factor crucial para proyecciones futuras (ARIMA).

Análisis de Fechas Especiales

Para evaluar empíricamente si las fechas comerciales más relevantes del calendario chileno generan picos de ventas estadísticamente significativos, se cruzó el rango de fechas disponibles en la base de datos (del 09-11-2023 al 02-12-2024) con las siguientes festividades comerciales: Día de la Madre (segundo domingo de mayo), Navidad (24-25 de dic.), Día del Niño (segundo sábado de agosto), Fiestas Patrias (18-19 de sept.), Cyber Day (primeros de junio) y Black Friday (fines de nov.).

Al validar algorítmicamente, se encontró que todas estas fechas comerciales

caen dentro de la ventana global de 390 días de nuestra base de datos. El detalle de validación de las 10 fechas evaluadas en el rango es el siguiente:

- [EN RANGO] Día de la Madre: 2024-05-12
- [EN RANGO] Navidad (1): 2023-12-24
- [EN RANGO] Navidad (2): 2023-12-25
- [EN RANGO] Fiestas Patrias (1): 2024-09-18
- [EN RANGO] Fiestas Patrias (2): 2024-09-19
- [EN RANGO] Día del Niño: 2024-08-10
- [EN RANGO] Cyber Day (1): 2024-06-03
- [EN RANGO] Cyber Day (2): 2024-06-04
- [EN RANGO] Cyber Day (3): 2024-06-05
- [EN RANGO] Black Friday: 2023-11-24

Se generó entonces una ventana comparativa de ± 7 días alrededor de cada fecha detectada. Sin embargo, para evitar que la planicie de bajo volumen al inicio de la serie (finales de 2023 y principios de 2024, atribuida a aperturas progresivas de sucursales) distorsione el promedio base "Normal" a la baja, se excluyó dicho periodo de rampa del test estadístico. **El corte del 1 de marzo de 2024 se determinó observando el punto exacto en el componente de tendencia de la descomposición estacional (Figura 6) donde el volumen diario se estabiliza por encima del sub-registro inicial.** Esta exclusión delimita el análisis estrictamente al rango del **01-03-2024 al 02-12-2024** (lo cual descarta del test a Black Friday 2023 y Navidad 2023). Esto consolida un total de 277 días analizables, desglosados en 63 días válidos en la ventana "Especial" frente a 214 días "Normales".

Análisis de Medias y Prueba de Mann-Whitney U:

Días en ventana especial validos (± 7 días): 63

Días normales validos: 214

Monto promedio diario (Especial): 125.132.607,98

Monto promedio diario (Normal): 117.425.115,86

Monto mediano diario (Especial): 105.899.315,00

Monto mediano diario (Normal): 90.886.205,00

Mann-Whitney U: U=7.430,0, p-value=2.174172e-01

Tamaño de efecto (rango-biserial): r=-0,1022 (magnitud pequeña)

Interpretación no técnica: Al comparar las ventas diarias dentro de la ventana de festividades contra el resto del año (descartando el periodo inicial inestable para mayor rigurosidad), se observa que la mediana y el promedio de ventas son superiores durante las fechas comerciales. Sin embargo, la varianza intrínseca de

las ventas diarias es muy alta. La prueba no paramétrica de Mann-Whitney U arroja un p-value de 0,217 ($> 0,05$), lo que significa que fallamos en rechazar la hipótesis nula: **no existe una diferencia estadísticamente significativa** entre el volumen de ventas de las ventanas comerciales y el resto del año consolidado. Esto confirma que las ventas de Cruz Morada, fuertemente ancladas en demandas de salud inelásticas, no logran un diferencial estadísticamente distinguible atribuible al retail masivo de estas fechas, descartando un pico estacional anómalo. Se adjunta el gráfico comparativo donde se delimita la exclusión del periodo de rampa en azul y se marcan en rojo las ventanas evaluadas.




Figura 8: Ventas Diarias vs Ventana de Fechas Especiales

6 Fase 3: Inferencia Estadística

Se pusieron a prueba cinco aseveraciones de negocio.

1. ¿El ticket promedio (MONTA APLICADO) en APP es mayor que en WEB?

- **Prueba:** Mann-Whitney U (p-value = 0,3603); tamaño de efecto rango-biserial $r = -0,001$ (insignificante).
- **Interpretación no técnica:** Dado que $0,36 > 0,05$, no rechazamos H_0 . No hay evidencia estadística de que un canal deje mayores tickets que el otro; el tamaño de efecto nulo lo confirma. La diferencia aparente es azar de la muestra.

2. ¿El % de descuento afecta las unidades vendidas?

- **Interpretación no técnica:** Imposible de calcular estadísticamente, puesto que todo cliente en esta base de datos compró exactamente 1 unidad (varianza nula). La regresión matemática se degenera.

3. (H. Propia 1) ¿El ticket promedio difiere según el GÉNERO?

- **Prueba:** Mann-Whitney U (p-value = 0,0000); tamaño de efecto rango-biserial $r = -0,047$ (**insignificante**).

- **Interpretación no técnica:** Se rechaza H_0 ($p < 0,05$): los clientes masculinos registran tickets levemente más altos (\$10.698) que las clientas femeninas (\$9.929). **Matiz clave:** con $N = 3,2M$ el p -value es prácticamente 0 por el tamaño muestral, pero el tamaño de efecto ($r = -0,047$) muestra que la diferencia, aunque real, es **prácticamente despreciable**.

4. (H. Propia 2) ¿La edad está relacionada con la frecuencia de compra?

- **Prueba:** Correlación de Spearman ($\rho = 0,127$, p -value = 0,0000); el propio ρ es el tamaño de efecto (magnitud pequeña).
- **Interpretación no técnica:** Se rechaza H_0 ($p < 0,05$). A mayor edad del cliente hay mayor propensión a visitar la farmacia más veces, aunque la asociación es débil ($\rho = 0,127$).

5. (H. Propia 3) ¿El nivel de descuento otorgado varía según el CANAL (POS, APP, WEB)?

- **Prueba:** Kruskal-Wallis (p -value = 0,0000); tamaño de efecto $\eta^2 = 0,005$ (insignificante).
- **Interpretación no técnica:** Se rechaza H_0 ($p < 0,05$): la política de descuentos depende del canal de ingreso. No obstante, el η^2 indica que el canal explica una fracción mínima de la variación del descuento.

7 Fase 4: Modelado Predictivo (Regresión OLS)

Se empleó el modelo de **Opción A (Regresión Lineal Múltiple)** para predecir el MONTO APLICADO. El modelo final es $\text{MONTO} \sim \text{PORCENTAJE DESCUENTO} + \text{CANAL}$. De los cuatro predictores sugeridos por la rúbrica se excluyeron dos, con justificación estadística: UNIDADES (constante, varianza cero: perfectamente colineal con el intercepto) y LOCAL (identificador nominal de alta cardinalidad y, además, estructuralmente colineal con CANAL —los canales online se registran en un único local virtual—, lo que vuelve singular la matriz de diseño). Ambas exclusiones y su diagnóstico se detallan en la Sección 10; el efecto categórico de LOCAL sobre el monto ya quedó caracterizado en el EDA (Kruskal-Wallis, $\eta^2 = 0,0156$). El conjunto se dividió 70 % Entrenamiento y 30 % Prueba.

Coefficientes de la Regresión OLS (Datos no estandarizados):

Variable	Coef	Std Err	t	P> t
const	-11.070,00	32,98	-335,704	0,000
PORCENTAJE DESCUENTO	54.320,00	81,29	668,213	0,000
CANAL_WEB	-668,77	56,51	-11,834	0,000
CANAL_CCT	-2.600,82	1.082,15	-2,403	0,016
CANAL_APP	-1.683,88	76,34	-22,058	0,000

Interpretación de Coeficientes en el Negocio: Al utilizar deliberadamente los datos en bruto (sin estandarizar), la regresión permite traducir los coeficientes directamente a pesos chilenos:

- **Descuento:** manteniendo el canal constante, pasar de 0 % a 100 % de descuento se asocia a un aumento de \$54.320 CLP en el monto. Esta aparente paradoja (más descuento, más monto) es **correlacional, no causal**: los mayores descuentos absolutos se aplican a medicamentos de especialidad cuyo precio base es muy alto. El intercepto ($-\$11.070$) no es interpretable de forma aislada (equivaldría a extrapolar a descuento 0 %); evaluado en el descuento medio (0,392) reproduce el ticket promedio observado ($\sim \$10.180$).
- **Canal:** el canal base (intercepto) es POS (presencial). Todos los canales reducen el ticket relativo al POS: WEB $-\$668,77$, APP $-\$1.683,88$ y CCT (Call Center) $-\$2.600,82$. CCT exhibe la mayor reducción pero también el mayor error estándar (1.082,15), coherente con su volumen marginal (226 transacciones).
- **Predictores excluidos:** UNIDADES (constante) y LOCAL (nominal y colineal con CANAL) se excluyeron *a priori* por las razones detalladas en la Sección 10. Gracias a ello la matriz de diseño es no singular y todos los VIF resultan $\approx 1,0$ (sin artefactos de pseudoinversa).

7.1 Validación y Diagnóstico de Supuestos

Diagnóstico y Métricas:

Ajuste en entrenamiento:

R-cuadrado: 0,1645 R-cuadrado ajustado: 0,1645

Validación (conjunto de prueba 30%):

R-cuadrado (prueba): 0,1640

RMSE: 13.220,88

MAE: 6.291,93

Homocedasticidad (Breusch-Pagan): p-value=0,0000 (Heterocedasticidad)

Normalidad residuos (Shapiro-Wilk): p-value=1.10e-78 (NO normales)

Independencia (Durbin-Watson): 1,9987 (Sin autocorrelación)

El modelo falla gravemente en cumplir los supuestos OLS clásicos. La heterocedasticidad se evidencia en el embudo asimétrico del gráfico de residuales. Asimismo, el QQ-Plot demuestra que los errores están muy sesgados a la derecha.




Figura 9: Residuales vs Ajustados




Figura 10: QQ-Plot de Residuos




Figura 11: Histograma de Residuales

El único supuesto que se cumple perfectamente es la **Ausencia de Multicolinealidad**. **Factor de Inflación de Varianza (VIF):**

PORCENTAJE DESCUENTO:	VIF=1,0041 (sin colinealidad)
CANAL_WEB:	VIF=1,0024 (sin colinealidad)
CANAL_CCT:	VIF=1,0000 (sin colinealidad)
CANAL_APP:	VIF=1,0024 (sin colinealidad)

Todos los VIF son $\approx 1,0$: los predictores del modelo final son mutuamente independientes. Este resultado limpio es consecuencia directa de haber excluido a priori a UNIDADES y LOCAL (ver Sección 10); en versiones previas del modelo, su inclusión producía VIF de hasta 10^{11} y coeficientes de pseudoinversa —el diagnóstico que motivó su exclusión.

7.2 Interpretación Crítica y Extrapolabilidad

El modelo presenta un R^2 ajustado muy pobre (0,1645 en entrenamiento; el R^2 sobre el conjunto de prueba es 0,1640), explicando apenas $\sim 16,4\%$ de la varianza del ticket final, con un error absoluto medio (MAE) de \$6.291,93 CLP.

¿El modelo es extrapolable? No. El modelo es puramente descriptivo básico y sufre de **omisión de variables críticas**. Intentar predecir el total a pagar utilizando si compró en la APP o el POS, ignorando la variable de negocio de mayor peso físico (el **precio base o SKU** de los medicamentos), produce coeficientes estadísticamente sesgados. Este error de diseño genera la ruptura generalizada de los supuestos visualizada en los residuales, imposibilitando la extrapolación causal de los hallazgos al negocio real.

8 Síntesis de Resultados (Cuadro de Mando)

La Tabla 5 reúne, de forma ordenada, las métricas clave de las cuatro fases y de la evaluación de rendimiento. Es un resumen de referencia: la justificación de cada decisión y la interpretación de cada número se desarrollan en la sección correspondiente; aquí se consolidan para una lectura rápida.

Métrica	Valor	Lectura
Fase 1 — Datos y Preprocesamiento		
Registros procesados	$3.242.878 \times 9$ col.	carga particionada (Dask)
Clientes únicos	1.183.242	frecuencia por cliente
Nulos reales (DESCUENTO, F. NAC.)	0,00 %	imputación preventiva
Edades inválidas imputadas	2.876 (mediana 49,9)	ruido, no “missing”
Outliers de MONTO (IQR)	149.377 (4,61 %)	se marcan, no se eliminan
Fase 2 — Exploratorio (EDA) (magnitud práctica vía tamaño de efecto)		
Normalidad de MONTO (Shapiro)	$p = 2,9 \times 10^{-84}$	no normal $\Rightarrow$ Spearman
MONTO $\sim$ DESCUENTO (Spearman)	$\rho \approx 0,48$	asociación positiva (media)
CANAL $\sim$ LOCAL (Chi ²)	V de Cramér = 0,577	dependientes (asoc. grande)
MONTO $\sim$ CANAL (Kruskal)	$H = 5.950,5; \eta^2 = 0,0018$	difiere; efecto insignificante
MONTO $\sim$ LOCAL (Kruskal)	$H = 51.345,7; \eta^2 = 0,0156$	difiere; efecto pequeño
Fase 3 — Inferencia (5 hipótesis)		
H1: APP > WEB (Mann-Whitney)	$p = 0,360; r = -0,001$	no se rechaza
H2: DESCUENTO $\rightarrow$ UNIDADES	degenerada	UNIDADES $\equiv 1$
Propia 1: GÉNERO (Mann-Whitney)	$p < 0,001; r = -0,047$	se rechaza, pero efecto insignif.
Propia 2: EDAD $\sim$ FREC. (Spearman)	$\rho = 0,127, p < 0,001$	se rechaza; efecto pequeño
Propia 3: DESCUENTO $\sim$ CANAL (Kruskal)	$H \approx 16.535; \eta^2 = 0,005$	se rechaza; efecto insignif.
Fechas especiales (Mann-Whitney)	$p = 0,217; r = -0,102$	sin pico estacional
Fase 4 — Modelo OLS (MONTO $\sim$ DESCUENTO + CANAL)		
R^2 ajustado (train) / R^2 (test)	0,1645 / 0,1640	ajuste pobre
RMSE / MAE	13.220,88 / 6.291,93	error elevado
Breusch-Pagan / Shapiro (resid.)	$p < 0,001 / p < 0,001$	heteroced.; no normal
Durbin-Watson / VIF	1,999 / $\approx 1,0$	sin autocorr.; sin colinealidad
Rendimiento y verificación (Sección 3)		
Mejor planificador	threads: 18,36 s total	1,27 $\times$ en preprocesamiento
processes / LocalCluster	0,32 $\times$ / óptimo estable	IPC vs. datos residentes
Tamaño de partición óptimo	64 MB (61,81 s)	vs. 32 MB / 128 MB
Integridad / Determinismo	26/26 / 37/37	correcto y reproducible

Tabla 5: Cuadro de mando: síntesis de las métricas clave del análisis y de la evaluación de rendimiento. Cada valor se explica e interpreta en su sección respectiva.

9 Conclusiones y Recomendaciones de Negocio

Integrando los hallazgos de las cuatro fases, se extraen las siguientes conclusiones para Cruz Morada:

- **Demanda inelástica, sin estacionalidad comercial.** Las ventas no muestran un pico estadísticamente significativo en las fechas comerciales del calendario chileno (Mann-Whitney $p = 0,217$; efecto pequeño $r = -0,10$). Es coherente con un negocio de salud: la demanda de medicamentos es relativamente inelástica y no sigue los ciclos del retail masivo. **Recomendación:** no sobreinvertir en campañas atadas a fechas comerciales; la serie sí exhibe fuerte autocorrelación (ACF), por lo que la planificación de inventario se beneficiaría más de un modelo de series de tiempo (ARIMA) que de calendarios promocionales.
- **Diferencias reales pero prácticamente irrelevantes.** Género, canal y local arrojan diferencias “altamente significativas” ($p \rightarrow 0$) que, medidas por tamaño de efecto, son **insignificantes o pequeñas** ($r = -0,047$ para género; $\eta^2 = 0,0018$ y $0,0156$ para canal y local). El gran N (3,2M) hace que casi todo sea significativo; la magnitud real es lo que importa para el negocio. **Recomendación:** no segmentar la estrategia de precios por género ni por canal esperando un impacto material en el ticket.
- **El ticket lo gobierna el precio base del producto, no las variables disponibles.** El modelo OLS explica solo $\sim 16\%$ de la varianza del monto ($R^2 = 0,164$), con residuos heterocedásticos y no normales. La relación positiva descuento–monto es un **artefacto de confusión**: los mayores descuentos se aplican a medicamentos de especialidad de precio alto. **Recomendación:** para predecir o entender el ticket, incorporar la variable omitida de mayor peso —el SKU/precio base del producto—, ausente en este conjunto.
- **Confusión estructural canal–local.** Los canales online se registran en un local virtual único (LOCAL 1999), lo que confunde canal y local (V de Cramér 0,577). Es un aspecto a considerar en cualquier análisis futuro por tienda: el “local” online no es una sucursal física.
- **Eficiencia computacional.** Para este volumen (dataset denso que cabe en RAM, una sola máquina de 10 núcleos), el planificador threads es el óptimo ($1,3\times$); el multiproceso ingenuo (processes) *degrada* el rendimiento por IPC, y LocalCluster es la vía correcta de escalamiento a datos mayores o múltiples nodos. **Recomendación:** mantener threads en producción y migrar a LocalCluster solo si el volumen supera la memoria.

10 Dificultades Encontradas y Solución de Problemas

1. **Desbordamiento de Memoria (OOM):** Al intentar cargar masivamente con pandas, el sistema colapsaba.

Solución: Implementar el motor Dask DataFrame con lectura lazy y particiones (chunks), procesando las 3,2M de filas en ~ 15 segundos con el planificador threads (véase la evaluación de rendimiento de la Sección 3, que además demuestra por qué el planificador processes degradaría este tiempo a ~ 61 s por sobre costo de IPC).

2. **Matriz de diseño singular por dos fuentes de colinealidad (OLS).** Un primer diseño ingenuo del modelo, siguiendo literalmente la rúbrica (MONTO $\sim$ DESCUENTO + UNIDADES + LOCAL + CANAL), producía una matriz de diseño **singular** y coeficientes absurdos del orden de 10^{12} (artefacto de la pseudoinversa de Moore-Penrose). El diagnóstico reveló **dos** fuentes independientes de colinealidad perfecta:

- UNIDADES es constante ($\equiv 1$, varianza 0): es una copia del intercepto, por lo que es linealmente dependiente de const.
- LOCAL está **estructuralmente confundido con** CANAL: el diagnóstico mostró que el indicador LOCAL_1999 es *idéntico* a la suma de los indicadores de canal online (los coeficientes de pseudoinversa aparecen con igual magnitud y signo opuesto, prueba de una dependencia lineal exacta). Esto revela que los canales online (WEB, APP, CCT) se registran en un único “local virtual” (LOCAL 1999), lo que es coherente con la alta V de Cramér (0,577) medida en el EDA.

Solución: en lugar de imputar valores de resguardo (que enmascararían el problema), se **excluyeron ambas variables de forma principia**da. UNIDADES no aporta varianza; LOCAL es nominal, de alta cardinalidad, colineal con CANAL en la dimensión online/físico y de efecto marginal pequeño ($\eta^2 = 0,0156$), por lo que su inclusión no compensa la pérdida de identificabilidad. El modelo final (MONTO $\sim$ DESCUENTO + CANAL) es no singular, con todos los VIF $\approx 1,0$ y coeficientes interpretables. El efecto de LOCAL sobre el monto queda documentado por separado en el EDA (Kruskal-Wallis, $\eta^2 = 0,0156$).

A Anexo A: Ejecución de Referencia (Prueba de Ejecución)

Este anexo reproduce **literalmente** la salida por pantalla de una ejecución completa del programa, obtenida con `CPYD_SEED=42 python3 main.py data/ventas_completas.csv` en el equipo de la Tabla 1 (Apple M4, planificador threads). Sirve de *prueba de ejecución*: los números del informe son la salida real y reproducible del pipeline, no valores inventados. Cada bloque se antecede de una explicación de *qué demuestra*. Se omite una tabla de contingencia de 792 filas por brevedad; las líneas muy anchas de la salida cruda se muestran cortadas con el símbolo $\hookrightarrow$ para no exceder el margen.

Fase 1 — Carga y Preprocesamiento (paralelo con Dask)

Qué demuestra: la semilla se fija desde CPYD_SEED; el planificador activo es threads (10 *workers*); las pruebas MCAR confirman **0 % de nulos reales**. Se computan en paralelo la frecuencia de **1.183.242 clientes**, la imputación de **2.876 edades** inválidas (mediana 49,9) y los descriptivos; se materializan **3.242.878 filas** y se marcan **149.377 outliers** (IQR, 4,61 %). UNIDADES da asimetría/curtosis NA por varianza cero (esperado).

```
=====
SISTEMA DE ANÁLISIS ESTADÍSTICO Y MODELADO DE VENTAS
=====
Archivo de entrada: data/ventas_completas.csv
[Determinismo] Semilla configurada desde CPYD_SEED: 42

[Paso 1/4] Preprocesamiento y limpieza de datos (paralelo con Dask)...
[Paralelo] Planificador multihilo (memoria compartida, limitado por GIL para ops CPU-bound de
↪ pandas) con 10 workers.
[Determinismo] Semilla configurada desde CPYD_SEED: 42

--- Prueba de mecanismo de valores faltantes (MAR vs MCAR) ---
Proporción de nulos en PORCENTAJE DESCUENTO (muestra de 50,000): 0.0000%
Tabla de contingencia (CANAL vs DESCUENTO nulo):
PORCENTAJE DESCUENTO  False
CANAL
POS                    49890
WEB                    110
No hay valores nulos suficientes en la muestra para la prueba de independencia.
Cargando con Dask (bloques de 64MB, parseo paralelo) desde: data/ventas_completas.csv
[Paralelo] 10 particiones lógicas (una tarea por bloque).

--- Prueba de mecanismo de valores faltantes para FECHA NACIMIENTO ---

Proporción de nulos globales (muestra de 3,242,878): 0.0000%
Tabla de contingencia (CANAL vs FECHA NACIMIENTO nulo):
FECHA_NAC_ES_NULO      0
CANAL
POS                    3119427
WEB                    79987
CCT                     226
APP                    43238
No hay valores nulos suficientes en la muestra para la prueba de independencia con CANAL.

Proporción de nulos globales (muestra de 3,242,878): 0.0000%
Tabla de contingencia (LOCAL vs FECHA NACIMIENTO nulo):
[ ... tabla de 792 locales omitida por brevedad: 0% de nulos ... ]
No hay valores nulos suficientes en la muestra para la prueba de independencia con LOCAL.
[Paralelo] Frecuencia de 1,183,242 clientes calculada en 0.84 s.

Edades inválidas o faltantes detectadas: 2,876. Se imputan con la mediana (49.9 años).
[Paralelo] Estadísticos descriptivos calculados en 0.82 s sobre 6 columnas.

Estadísticos descriptivos calculados en paralelo:
UNIDADES: media=1.0000, desv_std=0.0000, minimo=1.0000, maximo=1.0000, asimetria=NA, curtosis=NA
PORCENTAJE DESCUENTO: media=0.3920, desv_std=0.1080, minimo=0.0000, maximo=1.0000,
↪ asimetria=0.2969, curtosis=2.8491
MONTO APLICADO: media=10,179.9777, desv_std=14,453.2397, minimo=15.0000, maximo=226,476.0000,
↪ asimetria=9.0603, curtosis=108.2272
MONTO POR UNIDAD: media=10,179.9777, desv_std=14,453.2397, minimo=15.0000, maximo=226,476.0000,
↪ asimetria=9.0603, curtosis=108.2272
EDAD: media=49.5745, desv_std=16.7247, minimo=0.0055, maximo=109.8453, asimetria=0.2419,
↪ curtosis=-0.7823
FRECUENCIA CLIENTE: media=5.6542, desv_std=5.4562, minimo=1.0000, maximo=110.0000,
↪ asimetria=3.2557, curtosis=21.5177

Materializando DataFrame limpio en memoria (compute paralelo)...
DataFrame limpio: 3,242,878 filas, 10 columnas.

Detección de outliers en MONTO APLICADO (método IQR):
```

Rango aceptable: [-4,562.50, 23,929.50]
 Outliers detectados: 149,377 (4.61%)
 Decisión: se marcan pero no se eliminan; corresponden a compras reales de alto valor (medicamentos
 ↪ especializados), no a errores de registro.

Estandarizando variables continuas: ['PORCENTAJE DESCUENTO', 'MONTO APLICADO', 'MONTO POR UNIDAD',
 ↪ 'EDAD', 'FRECUENCIA CLIENTE']
 PORCENTAJE DESCUENTO: media=0.3920, desv_std=0.1080
 MONTO APLICADO: media=10179.9777, desv_std=14453.2374
 MONTO POR UNIDAD: media=10179.9777, desv_std=14453.2374
 EDAD: media=49.5745, desv_std=16.7247
 FRECUENCIA CLIENTE: media=5.6542, desv_std=5.4562

Preprocesamiento finalizado.

Fase 2 — Análisis Exploratorio (EDA)

Qué demuestra: ninguna variable es normal (Shapiro/KS, $p \ll 0,05$), justificando Spearman y pruebas no paramétricas. Con **tamaños de efecto:** V de Cramér(CANAL,LOCAL)= 0,577 (grande, por el confinamiento online=LOCAL 1999), pero η^2 de MONTO por CANAL (0,0018) y LOCAL (0,0156) son insignificante/pequeño: con $N = 3,2M$ todo es “significativo”, pero la magnitud práctica es baja. Fechas especiales: $p = 0,217$ (rango-biserial -0,102), sin pico estacional.

[Paso 2/4] Análisis exploratorio y visualizaciones...

=== 1) Estadística Descriptiva ===

	UNIDADES ↪ FRECUENCIA CLIENTE	PORCENTAJE DESCUENTO	MONTO APLICADO	MONTO POR UNIDAD	EDAD
Media	1.0	0.3920	1.017998e+04	1.017998e+04	49.5745
↪ 5.6542					
Mediana	1.0	0.4000	7.662000e+03	7.662000e+03	48.6297
↪ 4.0000					
Varianza	0.0	0.0117	2.088961e+08	2.088961e+08	279.7172
↪ 29.7698					
Desv. Estándar	0.0	0.1080	1.445324e+04	1.445324e+04	16.7247
↪ 5.4562					
Mínimo	1.0	0.0000	1.500000e+01	1.500000e+01	0.0055
↪ 1.0000					
Máximo	1.0	1.0000	2.264760e+05	2.264760e+05	109.8453
↪ 110.0000					
Asimetría	0.0	0.2969	9.060300e+00	9.060300e+00	0.2419
↪ 3.2557					
Curtosis	0.0	2.8491	1.082274e+02	1.082274e+02	-0.7823
↪ 21.5178					

=== 2) Pruebas de Normalidad (muestra de 5,000, los tests se degradan con millones de filas) ===

PORCENTAJE DESCUENTO:

Shapiro-Wilk: W=0.8562, p-value=1.600758e-55
 Kolmogorov-Smirnov: D=0.1951, p-value=3.514943e-167
 Conclusión: la variable NO sigue una distribución normal.

MONTO APLICADO:

Shapiro-Wilk: W=0.3967, p-value=2.901537e-84
 Kolmogorov-Smirnov: D=0.2539, p-value=1.268822e-284
 Conclusión: la variable NO sigue una distribución normal.

EDAD:

Shapiro-Wilk: W=0.9797, p-value=3.788937e-26
 Kolmogorov-Smirnov: D=0.0487, p-value=1.000633e-10
 Conclusión: la variable NO sigue una distribución normal.

Generando histogramas con curvas de densidad...

Generando boxplots por categoría...

=== 3) Matriz de Correlación con Prueba de Significancia ===

Coefficientes de Spearman (elegido por la no-normalidad de las variables):

	UNIDADES	PORCENTAJE DESCUENTO	MONTO APLICADO	EDAD	FRECUENCIA CLIENTE
UNIDADES	1.0	NaN	NaN	NaN	NaN

PORCENTAJE DESCUENTO	NaN	1.0000	0.4840	-0.0033	0.2967
MONTO APLICADO	NaN	0.4840	1.0000	0.0974	0.2214
EDAD	NaN	-0.0033	0.0974	1.0000	0.1272
FRECUENCIA CLIENTE	NaN	0.2967	0.2214	0.1272	1.0000

p-valores asociados:

	UNIDADES	PORCENTAJE DESCUENTO	MONTO APLICADO	EDAD	FRECUENCIA CLIENTE
UNIDADES	0.000e+00	indefinido	indefinido	indefinido	indefinido
PORCENTAJE DESCUENTO	indefinido	0.000e+00	0.000e+00	1.351e-01	0.000e+00
MONTO APLICADO	indefinido	0.000e+00	0.000e+00	0.000e+00	0.000e+00
EDAD	indefinido	1.351e-01	0.000e+00	0.000e+00	0.000e+00
FRECUENCIA CLIENTE	indefinido	0.000e+00	0.000e+00	0.000e+00	0.000e+00

=== 4) Pruebas de Asociación ===

Chi-cuadrado de independencia (CANAL vs LOCAL):

Chi2=3242878.0000, gl=2373, p-value=0.000000e+00

Tamaño de efecto (V de Cramér): 0.5774 (asociación grande)

Conclusión: CANAL y LOCAL dependen entre sí.

Nota: con N muy grande el p-value es ~0 casi por construcción; la V de Cramér mide la MAGNITUD

→ real de la asociación.

Correlaciones entre UNIDADES, MONTO APLICADO y PORCENTAJE DESCUENTO (Spearman):

UNIDADES vs MONTO APLICADO: correlación indefinida (UNIDADES tiene varianza cero).

UNIDADES vs PORCENTAJE DESCUENTO: correlación indefinida (UNIDADES tiene varianza cero).

MONTO APLICADO vs PORCENTAJE DESCUENTO: rho=0.4827, p-value=0.000000e+00

ANOVA de un factor (MONTO APLICADO ~ CANAL):

ANOVA paramétrico: F=152.5429, p-value=7.367832e-99

Kruskal-Wallis (no paramétrico): H=5950.5194, p-value=0.000000e+00

Tamaño de efecto (eta²): 0.0018 (magnitud insignificante)

Conclusión: el monto difiere significativamente entre niveles de CANAL (pero el tamaño de efecto

→ indica relevancia práctica insignificante).

ANOVA de un factor (MONTO APLICADO ~ LOCAL):

ANOVA paramétrico: F=37.8254, p-value=0.000000e+00

Kruskal-Wallis (no paramétrico): H=51345.7439, p-value=0.000000e+00

Tamaño de efecto (eta²): 0.0156 (magnitud pequeña)

Conclusión: el monto difiere significativamente entre niveles de LOCAL (pero el tamaño de efecto

→ indica relevancia práctica pequeña).

=== 5) Análisis de Patrones Temporales ===

Serie diaria construida: 390 días (2023-11-09 a 2024-12-02).

Descomposición y gráficos ACF/PACF guardados en 'plots/'.

--- Análisis de Fechas Especiales ---

Fechas candidatas evaluadas y su estado:

[EN RANGO] Día de la Madre: 2024-05-12

[EN RANGO] Navidad (1): 2023-12-24

[EN RANGO] Navidad (2): 2023-12-25

[EN RANGO] Fiestas Patrias (1): 2024-09-18

[EN RANGO] Fiestas Patrias (2): 2024-09-19

[EN RANGO] Día del Niño: 2024-08-10

[EN RANGO] Cyber Day (1): 2024-06-03

[EN RANGO] Cyber Day (2): 2024-06-04

[EN RANGO] Cyber Day (3): 2024-06-05

[EN RANGO] Black Friday: 2023-11-24

Excluyendo período de rampa (antes de 2024-03-01) para evitar sesgo en el baseline:

Días en ventana especial validos (#7 días): 63

Días normales validos: 214

Monto promedio (Especial): 125132607.98

Monto promedio (Normal): 117425115.86

Monto mediano (Especial): 105899315.00

Monto mediano (Normal): 90886205.00

Mann-Whitney U: U=7430.0, p-value=2.174172e-01

Tamaño de efecto (rango-biserial): r=-0.1022 (magnitud pequeña)

Análisis exploratorio finalizado. Visualizaciones guardadas en 'plots/'.

Fase 3 — Inferencia Estadística (5 hipótesis)

Qué demuestra: H1 (APP>WEB) no se rechaza ($p = 0,360$, $r = -0,001$); H2 es degenerada (UNIDADES constante); las tres hipótesis propias se rechazan ($p < 0,001$), pero sus tamaños de efecto son insignificantes/pequeños (género $r = -0,047$; edad~frecuencia $\rho = 0,127$; descuento~canal $\eta^2 = 0,005$): efectos reales de escasa relevancia práctica.

[Paso 3/4] Inferencia estadística y pruebas de hipótesis...

=== Inferencia Estadística: Pruebas de Hipótesis ===

Hipótesis 1: el ticket promedio (MONTO APLICADO) en APP es mayor que en WEB.

Media APP: 10,750.44 (N=43,238)

Media WEB: 11,167.70 (N=79,987)

T-test de Welch (unilateral): $t=-5.3079$, $p\text{-value}=9.999999e-01$

Mann-Whitney U (no paramétrico): $U=1731369237.5000$, $p\text{-value}=3.603635e-01$

Tamaño de efecto (rango-biserial): $r=-0.0012$ (magnitud insignificante)

No se rechaza H0 ($p \geq 0.05$): no hay evidencia de efecto significativo.

Hipótesis 2: el % de descuento afecta significativamente las unidades vendidas.

Desviación estándar de UNIDADES: 0.0000

UNIDADES tiene varianza cero (todas las transacciones registran 1 unidad).

La regresión UNIDADES ~ DESCUENTO es matemáticamente degenerada: no existe variación que explicar,

→ por lo que la hipótesis no es evaluable en estos datos.

Hipótesis propia 1: el ticket promedio difiere según GÉNERO (1=Masculino, 2=Femenino).

Media Masculino: 10,698.75 (N=1,055,885)

Media Femenino: 9,929.51 (N=2,186,993)

T-test de Welch: $t=45.0372$, $p\text{-value}=0.000000e+00$

Mann-Whitney U: $U=1209372387023.5000$, $p\text{-value}=0.000000e+00$

Tamaño de efecto (rango-biserial): $r=-0.0474$ (magnitud insignificante)

Se rechaza H0 ($p < 0.05$): el efecto es estadísticamente significativo.

Hipótesis propia 2: la edad y la frecuencia de compra están monotónicamente asociadas.

Spearman: $\rho=0.1272$, $p\text{-value}=0.000000e+00$

Se rechaza H0 ($p < 0.05$): el efecto es estadísticamente significativo.

Hipótesis propia 3: el descuento promedio varía según el CANAL de compra.

ANOVA: $F=4399.1962$, $p\text{-value}=0.000000e+00$

Kruskal-Wallis: $H=16534.9211$, $p\text{-value}=0.000000e+00$

Tamaño de efecto (η^2): 0.0051 (magnitud insignificante)

Se rechaza H0 ($p < 0.05$): el efecto es estadísticamente significativo.

Fase 4 — Modelado Predictivo (Regresión OLS)

Qué demuestra: el modelo final $\text{MONTO} \sim \text{DESCUENTO} + \text{CANAL}$ (con UNIDADES y LOCAL excluidos y justificados). R^2 ajustado = 0,1645 (train), R^2 de prueba = 0,1640; RMSE = 13.220,88; MAE = 6.291,93. Diagnóstico: heterocedasticidad, no normalidad de residuos, independencia (Durbin-Watson = 1,999) y **ausencia de multicolinealidad** (todos los VIF $\approx 1,00$): la matriz de diseño ya no es singular tras las exclusiones.

[Paso 4/4] Ajuste y evaluación del modelo de regresión...

=== Modelado Predictivo: Regresión Lineal Múltiple (Opción A) ===

Variable objetivo: MONTO APLICADO.

Predictores: PORCENTAJE DESCUENTO (continua) y CANAL (categórica, dummies).

EXCLUSIONES JUSTIFICADAS:

- UNIDADES: constante (varianza 0), perfectamente colineal con el intercepto; incluirla es inválido (artefacto de pseudoinversa).
- LOCAL: identificador NOMINAL de alta cardinalidad (792 locales) y, además, ESTRUCTURALMENTE COLINEAL con CANAL: los canales online (WEB/APP/CCT) se registran en un único local virtual (LOCAL 1999),

por lo que incluir CANAL y LOCAL juntos vuelve SINGULAR la matriz de diseño. Su efecto categórico se caracteriza en el EDA (Kruskal por LOCAL).
Partición 70/30 -> train: 2,270,014, test: 972,864

Coeficientes del modelo OLS (statsmodels):

	coef	std err	t	P> t	[0.025	0.975]
const	-1.107e+04	32.984	-335.704	0.000	-1.11e+04	-1.1e+04
PORCENTAJE DESCUENTO	5.432e+04	81.287	668.213	0.000	5.42e+04	5.45e+04
CANAL_WEB	-668.7723	56.514	-11.834	0.000	-779.537	-558.007
CANAL_CCT	-2600.8160	1082.146	-2.403	0.016	-4721.784	-479.848
CANAL_APP	-1683.8770	76.340	-22.058	0.000	-1833.500	-1534.254

R²: 0.1645, R² ajustado: 0.1645

Validación en el conjunto de prueba (30%):

R² = 0.1640 | RMSE = 13,220.88 | MAE = 6,291.93

--- Diagnóstico de Supuestos del Modelo ---

Gráficos de diagnóstico guardados en 'plots/'.

Homocedasticidad (Breusch-Pagan): LM=209563.3423, p-value=0.000000e+00

Se rechaza homocedasticidad: hay heterocedasticidad en los residuos.

Normalidad de residuos (Shapiro-Wilk, muestra 5.000): W=0.5329, p-value=1.097612e-78

Los residuos NO siguen una distribución normal.

Independencia de residuos (Durbin-Watson): 1.9987 (valores cercanos a 2 indican ausencia de
↪ autocorrelación).

Multicolinealidad (VIF, vía inversa de la matriz de correlación de predictores):

PORCENTAJE DESCUENTO: VIF=1.0041 (sin colinealidad)

CANAL_WEB: VIF=1.0024 (sin colinealidad)

CANAL_CCT: VIF=1.0000 (sin colinealidad)

CANAL_APP: VIF=1.0024 (sin colinealidad)

Cierre — Tiempos por Fase

Qué demuestra: el planificador utilizado fue threads y el *pipeline* completo se resolvió en **~19,7 s** (preprocesamiento ~14,7 s, EDA ~2,9 s, OLS ~1,3 s). La diferencia con la Tabla 3 (~18,4 s para threads) es esperada: el arnés de *benchmark* omite la generación de figuras para aislar el costo de cómputo, mientras que esta ejecución de referencia sí produce todos los gráficos.

```
=====
PROCESAMIENTO COMPLETO FINALIZADO CON ÉXITO
Planificador Dask (Paso 1): threads
Tiempos por fase (perf_counter):
  Preprocesamiento (Dask-paralelo, incluye carga): 14.70 s
  EDA (secuencial, pandas/scipy): 2.85 s
  Inferencia (secuencial, scipy): 0.84 s
  Modelado OLS (secuencial, statsmodels): 1.31 s
Tiempo total del pipeline: 19.69 segundos.
Gráficos guardados en: /Users/aztellas/Documents/Trabajo-paralela-02/plots
=====
```